CP5 — Detecção de Ações de Pessoas com YOLO, U-Net e SlowFast

Applied Computer Vision 2026 — CheckPoint 5 · Prof. Dr. Paulo Sergio Rodrigues · Modelos pré-treinados integrados, sem treinamento adicional.

Membro	RM	Responsabilidade	Parecer (resumo)
[Nome do integrante 1]	[RM]	YOLO e leitura do vídeo	[parecer individual sobre os resultados]
[Nome do integrante 2]	[RM]	U-Net e projeção da máscara	[parecer individual sobre os resultados]
[Nome do integrante 3]	[RM]	SlowFast e janelas temporais	[parecer individual sobre os resultados]
[Nome do integrante 4]	[RM]	Integração, testes e apresentação	[parecer individual sobre os resultados]

1. Objetivo e pipeline

O programa lê um vídeo curto e produz, para cada trecho, três saídas sobrepostas no mesmo quadro: a caixa da pessoa, os pixels que pertencem a ela e a ação que ela realiza. Os três modelos são pré-treinados e nenhum recebeu treinamento adicional. O pipeline roda em quatro estágios independentes que gravam artefatos em disco — o enunciado pede que os modelos sejam executados separadamente, e a separação também mantém um único modelo por vez na memória, o que foi necessário porque a máquina de referência não tem GPU e dispõe de 6 GB de RAM.

Etapa	Modelo (pré-treinado, sem treino adicional)	Papel no pipeline
Detecção	YOLO11n (*ultralytics*), classe *person*, tracker ByteTrack	Localiza cada pessoa e mantém um *track_id* estável ao longo do tempo.
Segmentação	U²-Net *u2net_human_seg* (ONNX Runtime)	Produz a máscara da pessoa dentro do recorte da caixa. U²-Net é da família U-Net (*encoder-decoder* com *skip connections*, blocos RSU em estrutura U aninhada) e este checkpoint é pré-treinado para segmentação de pessoas.
Ação	SlowFast R50 8×8 (*pytorchvideo*), Kinetics-400	Classifica a ação em janelas de 32 quadros com passo 16, registrando top-1, top-5 e confiança por janela.

Integração YOLO + U-Net. O recorte da caixa é expandido em 10% antes de ir para a U-Net; sem essa folga o contorno sai cortado na borda do recorte, porque a rede não enxerga o entorno do sujeito. A máscara volta ao tamanho do recorte e é colada na posição original do quadro. **Integração com o SlowFast.** Cada janela recebe os 32 quadros no *fast pathway* e a subamostragem por *alpha*=4 no *slow pathway*. Com *roi=pessoa* a janela é recortada na união das caixas, de modo que o sujeito preencha o quadro; com *roi=quadro* usa-se a imagem inteira. Cada quadro herda a ação da janela que o contém e, nas regiões de sobreposição, vence a janela de maior confiança.

2. Tabela de resultados

Video	Ação observada	Cobertura YOLO	Conf. YOLO	IoU temp.	IDs / trocas do sujeito principal	Fill ratio da máscara	Acerto top-1	Acerto top-5	Conf. SlowFast
archery	archery	100%	0.81	0.97	2 / 6	0.24 (0.00-0.91)	100%	100%	1.00
pushups	push up	100%	0.93	0.99	1 / 0	0.35 (0.25-0.50)	82%	95%	0.81
skate	skateboarding	99%	0.63	0.77	124 / 44	0.06 (0.00-1.00)	68%	100%	0.70

Cobertura YOLO = fração de quadros com ao menos uma pessoa detectada. IoU temp. = IoU média entre as caixas do sujeito principal em quadros consecutivos (mede o quanto a caixa acompanha a pessoa). Trocas do sujeito principal = quantas vezes a maior caixa muda de track_id; com duas pessoas de tamanho parecido isso alterna sem que o rastreador tenha errado. Fill ratio = área da máscara dividida pela área da caixa, com mínimo e máximo entre parênteses. Acertos e confiança do SlowFast referem-se a *roi=pessoa*.

2.1. Custo de execução (CPU, sem GPU)

Video	Quadros	YOLO	U-Net	SlowFast (por ROI)	Total dos modelos
archery	300	12 s	259 s	20 s	5.2 min
pushups	360	15 s	179 s	26 s	4.1 min
skate	360	13 s	773 s	25 s	13.9 min

Medido na máquina de referência: Ubuntu 26.04, Python 3.14, 8 núcleos, 6 GB de RAM, **sem GPU**. Vídeos normalizados para 640 px e 30 fps. A coluna do SlowFast é o tempo de uma passagem; o total considera as duas ROIs (pessoa e quadro inteiro). A segmentação domina o custo porque roda uma vez por pessoa por quadro — é o estágio a otimizar primeiro.

3. Momentos analisados e as quatro perguntas

Os momentos abaixo não foram escolhidos a esmo: além de início, meio e fim de cada vídeo, o analisador inclui automaticamente todas as janelas em que o top-1 do SlowFast muda e o quadro de menor área de máscara — é exatamente onde o pipeline falha, e é isso que interessa examinar.

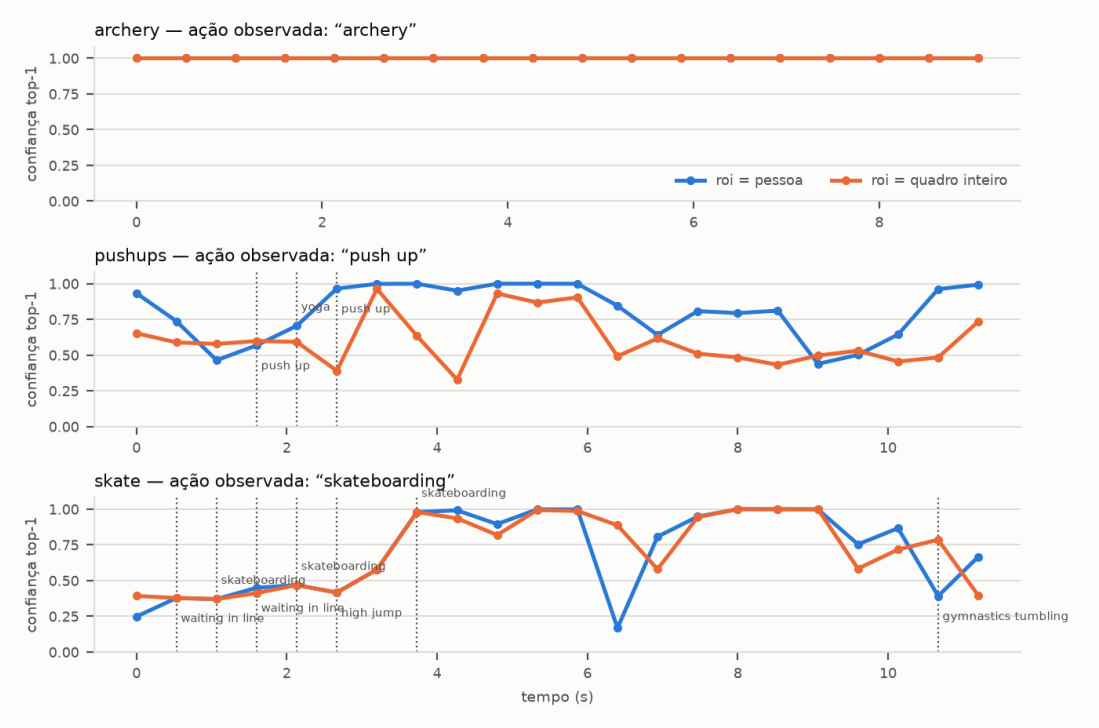
Video	t (s)	Motivo do recorte	YOLO	Máscara	SlowFast top-1	Conf.	OK?
archery	1.5	início	2p conf 0.8107	36358 px	archery	1.0	sim
archery	5.0	meio	2p conf 0.8287	16459 px	archery	1.0	sim
archery	8.5	fim	2p conf 0.8055	25608 px	archery	1.0	sim
archery	9.7	menor área de máscara	2p conf 0.8407	3936 px	archery	1.0	sim
pushups	1.6	troca de classe (yoga → push up)	1p conf 0.9396	11943 px	push up	0.5687	sim
pushups	1.8	início	1p conf 0.932	12744 px	push up	0.5687	sim
pushups	4.53	menor área de máscara	1p conf 0.885	6799 px	push up	0.9995	sim
pushups	6.0	meio	1p conf 0.9426	12225 px	push up	1.0	sim
pushups	10.2	fim	1p conf 0.9399	12230 px	push up	0.644	sim
skate	0.0	menor área de máscara	4p conf 0.6882	0 px	auctioning	0.248	nao
skate	1.07	troca de classe (waiting in line → skateboarding)	3p conf 0.7686	5 px	waiting in line	0.3781	nao
skate	1.8	início	7p conf 0.8757	17 px	waiting in line	0.4499	nao
skate	6.0	meio	3p conf 0.7672	0 px	skateboarding	0.9985	sim
skate	10.2	fim	4p conf 0.8885	12870 px	skateboarding	0.8663	sim

A caixa acompanha a pessoa? Sim, nos dois vídeos exigidos. A cobertura é de 100% dos quadros em *archery* e *pushups*, com IoU temporal média de 0,97 e 0,99 — a caixa gruda no sujeito mesmo durante o movimento rápido da flexão. O vídeo extra *skate* é o contraexemplo: a cobertura segue alta (99,4%), mas a IoU temporal cai para 0,77 e o rastreador emite 124 identidades para um punhado de pessoas reais (erro 3). Localizar é fácil; manter a identidade, não.

A máscara acompanha o contorno? Parcialmente, e é o elo mais frágil do pipeline. Em *pushups* a máscara é estável (variação média de área entre quadros de apenas 1,6%) mas sistematicamente incompleta: o *fill ratio* fica entre 0,25 e 0,50 porque braços e cabeça, finos e em contraluz, ficam de fora. Em *archery* a máscara é boa na maior parte do vídeo e colapsa por completo no trecho final (erro 1). Em *skate* o quadro é brutal: 68,9% das caixas saem sem máscara nenhuma e o *fill ratio* médio é de apenas 0,06.

A ação prevista corresponde ao trecho? Em *archery*, sim: 100% das 18 janelas classificam *archery* com confiança 1,00 — o vídeo é um clipe do próprio Kinetics-400, então funciona como verificação de sanidade do pré-processamento. Em *pushups* o top-1 acerta 82% das janelas e o top-5, 95%; os erros se concentram nos dois primeiros segundos, em que a pessoa ainda está se posicionando e o modelo responde *yoga*. Em *skate* o top-1 acerta 68% e o top-5 acerta **100%**: a classe certa está sempre entre as cinco primeiras, mas disputa com *high jump*, *gymnastics tumbling* e *waiting in line* — classes que descrevem bem o que mais ocupa a cena, que é gente parada assistindo.

A confiança cai ou a classe muda quando a ação começa ou termina? Sim, e de forma mensurável. Em *pushups* a confiança média nas janelas de troca de classe é 0,75, contra 0,82 nas estáveis; em *skate* a margem é ainda maior, 0,49 contra 0,79. O gráfico de *pushups* mostra o padrão completo: a curva parte de *yoga* na fase de preparação, sobe para 1,00 entre 3,7 s e 5,9 s — quando as repetições se sucedem sem pausa — e cai para o mínimo do vídeo, 0,44, por volta de 9 s. Inspecionando esse trecho, o mínimo não é um erro de pose: o atleta **sustenta a posição alta**, de braços estendidos, por mais de um segundo. A postura continua sendo a de uma flexão, mas o movimento praticamente cessa, e é o movimento que o *fast pathway* codifica. Em *archery*, onde a ação é contínua do primeiro ao último quadro, não há nenhuma troca de classe nem queda de confiança: o contraste entre os vídeos é a resposta.



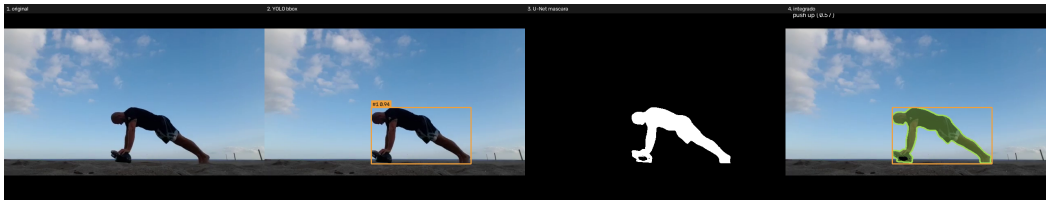
4. Erros observados e explicados

Erro 1 — A máscara da U-Net colapsa enquanto o YOLO continua correto (*archery*, t = 9,7 s).
No quadro 291 o YOLO detecta as duas arqueiras com confiança 0,83 e 0,84, o SlowFast mantém *archery* a 1,00, e a máscara simplesmente desaparece: restam fragmentos que cobrem 0,2% do recorte, contra 27,8% em um quadro bom do mesmo vídeo. **Diagnóstico medido:** a saliência bruta da U²-Net cai de máximo 1,000 e média 0,262 para máximo 0,646 e média 0,008. Baixar o limiar de 0,5 para 0,1 recupera apenas 3,6% do recorte (contra 32,2% no quadro bom), então não é problema de limiarização — é a própria resposta da rede que se anula. As duas caixas não se sobrepõem (IoU 0,000) e as proporções do recorte são praticamente idênticas nos dois quadros (26–29% × 90–94% do quadro), o que descarta oclusão e geometria do recorte como causa. **Causa raiz:** a U²-Net é um detector de objeto *saliente* e não recebe a caixa do YOLO como condicionante — ela apenas processa o recorte. Nada obriga a produzir máscara numa região onde já se sabe que há uma pessoa, então a etapa falha em silêncio. **O mesmo mecanismo em escala:** no vídeo *skate*, com multidão, **68,9% das caixas (1092 de 1586) produziram máscara vazia**, incluindo pessoas detectadas com confiança 0,86 e caixa de 27 mil pixels. No quadro 112, cinco caixas entram na U-Net e apenas uma sai com máscara: a do skatista em primeiro plano. Um segmentador condicionado pela caixa resolveria este modo de falha; baixar o limiar, não.



Quadro 291: original · caixas do YOLO · máscara da U-Net (quase vazia) · saída integrada.

Erro 2 — O SlowFast confunde a fase de preparação com *yoga* (*pushups*, 0–2,1 s).
As quatro primeiras janelas classificam *yoga* (confiança até 0,93) antes de estabilizar em *push up*. A causa é temporal, não espacial: a janela de 32 quadros cobre ~1,1 s e, nesse intervalo inicial, a pessoa está se abaixando e posicionando as mãos no chão — um movimento que de fato se parece mais com uma postura de ioga do que com uma flexão. O top-5 contém *push up* em 95% das janelas, ou seja, o modelo não ignora a classe correta, apenas a ordena abaixo nessa fase. O efeito é intrínseco à janela deslizante: toda fronteira de ação produz uma janela que mistura dois movimentos. Janelas menores reduziriam a mistura, mas o SlowFast 8×8 foi treinado com esse comprimento temporal e encurtá-lo degradaria as demais janelas.



Quadro 48 (1,6 s), janela em que o top-1 passa de *yoga* para *push up*.

Erro 3 — A multidão fragmenta as identidades do rastreador (*skate*).
Com 4,4 pessoas por quadro (máximo de 10), o ByteTrack emite **124 *track_ids* distintos em 360 quadros** para um punhado de pessoas reais. A mediana de vida de um *track* é de 5 quadros, e 66 dos 124 vivem 5 quadros ou menos: o rastreador perde e recria a mesma pessoa a cada oclusão mútua. O efeito aparece nas demais métricas — a IoU temporal cai de 0,97–0,99 nos outros vídeos para 0,77, e a confiança média do YOLO cai de 0,81–0,93 para 0,63. **Causa:** o ByteTrack associa por IoU entre quadros consecutivos, e numa plateia densa as caixas de pessoas diferentes se sobrepõem mais entre si do que a caixa de uma pessoa se sobrepõe a ela mesma depois de um movimento rápido. Vale separar os dois fenômenos: a *detecção* continua correta, com cobertura de 99,4% dos quadros. O que quebra é a identidade, não a localização — e é a identidade que o enunciado cobra ao perguntar se a caixa acompanha *a pessoa*.



Quadro 112: cinco pessoas detectadas, uma única máscara produzida (ver erro 1).

5. Extensão opcional: SlowFast no quadro inteiro vs no recorte

Video	Concordância top-1	Acerto top-1 (pessoa)	Acerto top-1 (quadro)	Conf. média (pessoa)	Conf. média (quadro)
archery	100%	100%	100%	1.00	1.00
pushups	36%	82%	36%	0.81	0.60
skate	86%	68%	77%	0.70	0.71

O resultado depende de haver um sujeito dominante, e os três vídeos cobrem os três casos. Em *archery* as duas variantes empatam em 100% de acerto e 1,00 de confiança: o sujeito já domina o quadro, então recortar não muda nada. Em *pushups* o recorte da pessoa acerta 82% das janelas contra 36% do quadro inteiro, com confiança média de 0,81 contra 0,60, e as duas variantes concordam em apenas 36% das janelas — a pessoa deitada ocupa uma faixa estreita no centro de um quadro dominado por céu e areia, e o *center-crop* de 256 px do pré-processamento descarta justamente as extremidades onde o movimento acontece. Em *skate* o recorte **não ajuda** (68% contra 77% do quadro inteiro), e a razão é estrutural: com 4,4 pessoas espalhadas pela cena, a união das caixas cobre praticamente o quadro todo (601×359 de 640×360), de modo que a variante *pessoa* degenera na variante *quadro* e só acrescenta tremor de recorte entre janelas. **Conclusão:** alimentar o SlowFast com o recorte da pessoa compensa quando há um sujeito único e pequeno em relação ao quadro; com multidão, a união das caixas perde o sentido e seria preciso recortar por *track*, um por vez.

6. Conclusão

A integração funciona e os três modelos pré-treinados se sustentam sem nenhum ajuste de pesos. A etapa mais confiável é a detecção, que mantém cobertura acima de 99% nos três vídeos; a mais frágil é a segmentação, porque a U-Net do pipeline não é condicionada pela caixa e pode falhar silenciosamente mesmo quando a detecção está correta — em cena com multidão, em quase 70% das caixas. O SlowFast é confiável enquanto a ação é contínua e identificável no vocabulário do Kinetics-400, e sua confiança é um indicador honesto: ela cai justamente nas fronteiras de ação, o que torna a própria confiança um sinal útil para segmentar o vídeo em trechos. Se fosse para estender o trabalho, a prioridade seria condicionar a máscara à detecção e recortar por *track* para o SlowFast — não trocar de classificador de ação.

Vídeos: *archery* — amostra de pesquisa do PyTorchVideo (clipe do Kinetics-400); *pushups* e *skate* — Wikimedia Commons, CC BY-SA 4.0. Procedência completa em data/videos/LICENSES.md. Código, métricas e vídeos de demonstração acompanham esta entrega.